

LAPORAN PROJECT
PENGOLAHAN CITRA DIGITAL
S1 SAINS DATA - UNIVERSITAS NEGERI SURABAYA

IDENTITAS PROYEK	
Judul	Klasifikasi Fraktur Tulang pada Citra X-Ray Menggunakan Metode Convolutional Neural Network (CNN)
Topik	Bone Fracture Detection
Identitas Penyusun	1. Kartika Nur Savira (24031554049) 2. Kevin Foreman Hutahaeon (24031554095) 3. Arimbi Deby Setyoningrum (24031554186)
Kelas	2024 C

1. PENDAHULUAN

Pendahuluan penelitian tidak lebih dari 1000 kata yang terdiri dari:

- A. Latar belakang dan rumusan permasalahan yang akan diteliti
- B. Pendekatan pemecahan masalah

1.1 Latar Belakang (min. 250 kata)

Citra *X-ray* merupakan salah satu alat penting dalam dunia medis yang digunakan untuk membantu proses diagnosis kondisi tulang, termasuk patah tulang [1]. Melalui citra ini, tenaga medis dapat mengamati struktur tulang secara langsung. Namun, proses analisis citra *X-ray* secara manual membutuhkan ketelitian yang tinggi dan sangat bergantung pada pengalaman tenaga medis. Hal ini berpotensi menimbulkan kesalahan dalam interpretasi, terutama ketika kualitas citra kurang baik atau terdapat banyak variasi kondisi gambar [2]. Seiring dengan perkembangan teknologi, khususnya dalam bidang pengolahan citra digital dan kecerdasan buatan, analisis citra dapat dilakukan secara otomatis menggunakan metode *deep learning* [3]. Salah satu metode yang banyak digunakan adalah *Convolutional Neural Network* (CNN), yang memiliki kemampuan untuk mengenali pola dan fitur penting dalam citra [4]. Dengan memanfaatkan CNN, proses klasifikasi citra *X-ray* dapat dilakukan secara lebih cepat, konsisten, dan efisien dibandingkan dengan metode manual. Namun demikian, performa model CNN sangat dipengaruhi oleh kualitas data yang digunakan. Citra *X-ray* sering memiliki variasi resolusi, tingkat kontras yang rendah, serta adanya *noise* yang dapat mengganggu proses ekstraksi fitur [1]. Selain itu, ketidakseimbangan jumlah data antar kelas (*class imbalance*) juga dapat menyebabkan model menjadi bias terhadap kelas tertentu [5]. Oleh karena itu, diperlukan tahap *preprocessing* yang tepat untuk meningkatkan kualitas citra sebelum digunakan dalam proses pelatihan model [6].

Berdasarkan hal tersebut, penelitian ini bertujuan untuk menganalisis pengaruh berbagai teknik *preprocessing* terhadap performa model CNN dalam klasifikasi citra *X-ray*. Dengan adanya penelitian ini, diharapkan dapat diperoleh metode *preprocessing* yang paling optimal untuk meningkatkan akurasi dan keandalan model dalam mendeteksi kondisi patah tulang.

Rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana karakteristik dataset citra *X-ray* yang digunakan dalam penelitian, khususnya dari segi distribusi kelas, resolusi, dan kualitas citra?
2. Bagaimana pengaruh berbagai teknik *preprocessing*, seperti resizing, normalisasi, CLAHE, dan filtering, terhadap kualitas citra *X-ray*?

3. Bagaimana performa model *Convolutional Neural Network* (CNN) dalam mengklasifikasikan citra *X-ray* berdasarkan teknik *preprocessing* yang digunakan?
4. Teknik *preprocessing* apa yang paling optimal untuk meningkatkan performa model CNN dalam mendeteksi fraktur tulang?

1.2 Pendekatan pemecahan masalah

Penelitian ini menggunakan pendekatan klasifikasi berbasis deep learning, khususnya *Convolutional Neural Network* (CNN), untuk mendeteksi fraktur tulang pada citra X-ray. Pendekatan ini dipilih karena CNN terbukti efektif dalam mengenali pola visual yang kompleks pada citra medis tanpa memerlukan *feature engineering* secara manual [4], [7].

Rumusan Masalah 1:

Melalui tahap *Exploratory Data Analysis* (EDA), yang mencakupi analisis distribusi kelas, pemeriksaan resolusi gambar, visualisasi sampel citra, serta analisis kontras menggunakan histogram intensitas piksel. Dari hasil EDA diketahui bahwa dataset memiliki 4.148 citra dengan 7 kelas fraktur, terdapat ketidakseimbangan kelas yang signifikan (dominan 420x512 px). Temuan ini menjadi dasar penentuan strategi *preprocessing* yang akan diterapkan [3].

Rumusan Masalah 2:

Setiap teknik memiliki peran tersendiri, dengan membangun 3 *pipeline preprocessing* untuk kemudian dibandingkan hasilnya. *Grayscale* menyederhanakan data input arena informasi warna tidak relevan pada citra X-ray. *Resize* menyeragamkan dimensi citra menjadi ukuran tetap sesuai kebutuhan input CNN. Normalisasi mengubah nilai piksel ke rentang 0-1 untuk mempercepat konvergensi model. CLAHE meningkatkan kontras lokal agar struktur tulang dan area fraktur lebih terlihat jelas. *Gaussian Blur* menghaluskan noise acak yang dapat mengganggu proses ekstraksi fitur [1], [6]. Pengaruh masing-masing teknik di evaluasi secara kuantitatif melalui performa model yang dihasilkan.

Rumusan Masalah 3:

Melatih model CNN menggunakan arsitektur yang sama dan konsisten pada setiap proses preprocessing. Sebelum pelatihan, dilakukan augmentasi data (flip, rotasi, zoom, dan perubahan brightness) pada data training untuk meningkatkan variasi data dan kemampuan generalisasi model, sekaligus membantu mengatasi ketidakseimbangan kelas [2], [5], [8]. Performa model dievaluasi menggunakan metrik accuracy, precision, recall, dan F1-score. Metrik recall menjadi perhatian utama karena dalam konteks medis, kesalahan dalam mendeteksi fraktur yang sebenarnya ada (*false negative*) memiliki dampak yang lebih serius dibandingkan jenis kesalahan lainnya [5].

Rumusan Masalah 4:

Membandingkan hasil evaluasi secara menyeluruh, dengan memperhatikan setiap teknik nya, dengan nilai metrik evaluasi terbaik, terutama recall dan F1-score, akan ditetapkan sebagai teknik preprocessing paling optimal.

2. Metodologi

Metodologi atau cara untuk mencapai tujuan yang telah ditetapkan ditulis tidak melebihi 1000 kata. Bagian ini berisi metode pre-processing dan/atau metode post processing yang dilengkapi dengan diagram alir penelitian yang menggambarkan apa yang sudah dilaksanakan dan yang akan dikerjakan selama waktu yang diusulkan.. Metode penelitian harus dibuat secara utuh dengan penahapan yang jelas. Tambahkan **diagram alur** juga.

2.1 Eksplorasi Dataset

Pemahaman dataset

2.1.1. Deskripsi Dataset

Dataset yang digunakan adalah *Bone Fracture Detection* berupa kumpulan citra X-ray yang digunakan untuk mendeteksi patah tulang menggunakan *computer vision*. Data dibagi

ke dalam beberapa kelas berdasarkan jenis patah tulang, seperti siku, jari, lengan bawah. Setiap gambar sudah dilengkapi anotasi untuk menunjukkan lokasi patahan.

Tabel 1. Deskripsi Data

Karakteristik	Keterangan
Nama Dataset	<i>Bone Fracture Detection Computer Vision Project</i>
Jenis Data	<i>Citra X-Ray</i>
Struktur Dataset	<i>Train, Validation, Test</i>
Format Label	<i>YOLO</i>
Jenis Klasifikasi	<i>Multi-class fracture detection</i>
Domain Data	<i>Medical imaging</i>

2.1.3. Exploratory Data Analysis

1. Distribusi Data

Dataset telah dibagi menjadi tiga subset yang merupakan standar dalam pelatihan model *machine learning*, yaitu *train*, *validation*, dan *test*.

Tabel 2. Distribusi Data


Subset	Jumlah Gambar
Train	3631
Validation	169
Test	348
Total	4148

2. Distribusi Kelas

Analisis distribusi kelas dilakukan dengan membaca file anotasi YOLO (.txt) yang berisi *class ID* yang dianotasi dalam citra X-ray. Setiap baris dalam file anotasi mewakili satu *bounding box* objek.

Tabel 3. Distribusi Kelas

Kelas	Jumlah	Keterangan
0	339	<i>Elbow positive</i>
1	531	<i>Fingers positive</i>
2	316	<i>Forearm fracture</i>
3	3	<i>Humerus fracture</i>
4	311	<i>Humerus</i>
5	360	<i>Shoulder fracture</i>
6	228	<i>Wrist positive</i>



Gambar 2. Visualisasi Distribusi Kelas


3. Data Imbalance

Ketidakeimbangan kelas adalah kondisi di mana jumlah sampel antar kelas berbeda secara signifikan. *imbalance* dievaluasi berdasarkan jumlah *bouding box* per kelas.

Temuan dari distribusi kelas:

1. *Class 1* memiliki jumlah anotasi terbanyak: 531 objek
2. *Class 3* memiliki jumlah anotasi paling sedikit: hanya 3 objek
3. Rasio ketidakeimbangan tertinggi: *Class 1* vs *Class 3* = 177 : 1
4. Kelas lain (0, 2, 4, 5, 6) memiliki distribusi yang relatif seimbang di kisaran 288-360


4. Visualisasi Sample




Gambar 3. Visualisasi Sample, (a) Elbow positive (b) *Fingers positive* (c) *Forearm fracture* (d) *Humerus fracture* (e) *Humerus* (f) *Shoulder fracture* (g) *Wrist positive*

5. Analisis Kontras

Analisis kontras bertujuan untuk memahami distribusi intensitas piksel dalam gambar X-Ray, digunakan untuk menentukan apakah teknik peningkatan kontras seperti *Histogram Equalization* atau CLAHE (*Contrast Limited Adaptive Histogram Equalization*) diperlukan dalam tahap *preprocessing*.





Gambar 4. Analisis Kontras, (0) *Elbow positive* (1) *Fingers positive* (2) *Forearm fracture* (3) *Humerus fracture* (4) *Humerus* (5) *Shoulder fracture* (6) *Wrist positive*

6. Distribusi Resolusi

Analisis resolusi gambar bertujuan untuk mengetahui variasi ukuran gambar dalam dataset. Informasi ini diperlukan untuk menentukan ukuran *resize* yang optimal.


Tabel 4. Distribusi Resolusi Gambar

Resolusi (px)	Jumlah Gambar
420×512	518
406×512	443
512×406	255
512×512	129
512×420	117

2.2 Langkah Penelitian

Langkah penelitian dan kesesuaian diagram alur

2.2.1. Diagram Alur



Gambar 5. Diagram Alur

2.2.2. Preprocessing

1. *Grayscale*

Grayscale adalah proses konversi citra RGB menjadi citra satu kanal intensitas. Pada citra X-ray, informasi warna tidak memberikan kontribusi signifikan terhadap analisis medis, sehingga hanya informasi intensitas yang dipertahankan. Proses ini menyederhanakan data *input* dan mengurangi kompleksitas komputasi CNN dalam mengekstraksi fitur penting dari citra [10].

2. *Resize*

Resize dilakukan untuk menyeragamkan ukuran seluruh citra agar sesuai dengan input CNN. Hal ini penting karena CNN membutuhkan *input* dengan dimensi yang konsisten. Standarisasi ukuran citra juga membantu meningkatkan efisiensi komputasi pelatihan model [7].

3. *Normalization*

Normalisasi dilakukan dengan mengubah nilai piksel ke rentang 0–1. Proses ini bertujuan untuk menstabilkan distribusi data dan mempercepat konvergensi model selama *training*. Normalisasi juga membantu mengurangi dominasi nilai piksel yang terlalu besar terhadap proses pembelajaran CNN [2].

4. *Contrast Limited Adaptive Histogram Equalization (CLAHE)*

CLAHE digunakan untuk meningkatkan kontras lokal pada citra X-ray. Teknik ini memperjelas area dengan kontras rendah sehingga struktur tulang dan potensi fraktur lebih mudah dikenali. CLAHE banyak digunakan dalam peningkatan citra medis karena mampu meningkatkan detail tanpa memperbesar *noise* secara signifikan [6]. Pada Proses ini kami menggunakan dua parameter pembanding yaitu *clipLimit* dan *tileGridSize*, *clipLimit* berfungsi untuk meningkatkan kontras pada citra yang ada, sedangkan *tileGridSize* berfungsi untuk menentukan seberapa detail atau lokal perubahan kontras tersebut akan diterapkan.

5. *Thresholding*

Adaptive Thresholding merupakan metode segmentasi citra yang menentukan nilai ambang (*threshold*) secara lokal pada setiap area citra sehingga lebih efektif digunakan pada citra dengan pencahayaan yang tidak merata. Metode ini terdiri dari Adaptive Mean Thresholding, yang menghitung nilai ambang berdasarkan rata-rata intensitas piksel pada area lokal, dan Adaptive Gaussian Thresholding, yang menggunakan rata-rata berbobot Gaussian sehingga piksel yang lebih dekat dengan pusat area memiliki pengaruh yang lebih besar dalam penentuan nilai ambang. Kedua metode ini memanfaatkan parameter *blockSize* untuk menentukan ukuran area lokal dan *C* sebagai konstanta pengurang nilai ambang [11].

6. *Augmentation*

Augmentasi data dilakukan untuk meningkatkan variasi dataset dan mengurangi *overfitting*. Teknik yang digunakan meliputi rotasi, *flipping*, *zoom*, dan perubahan *brightness*. Augmentasi sangat penting karena membantu model belajar lebih *robust* terhadap variasi data [5].

2.2.3. *Convolutional Neural Network (CNN)*

Convolutional Neural Network (CNN) digunakan untuk klasifikasi citra dengan mengekstraksi fitur spasial secara otomatis melalui lapisan *konvolusi*, *pooling*, dan *fully connected*. CNN bekerja dengan mempelajari fitur hierarkis dari citra, mulai dari fitur sederhana seperti tepi hingga pola struktur tulang, sehingga sangat efektif digunakan pada citra seperti X-ray. Pada penelitian ini, CNN digunakan untuk mengklasifikasikan citra menjadi fraktur dan non-fraktur karena kemampuannya dalam mengenali pola visual yang

kompleks tanpa memerlukan *feature engineering* manual, serta telah terbukti luas dalam berbagai aplikasi *medical image analysis* [4], [7], [10].

2.2.4. Classification

Tahap klasifikasi dilakukan setelah proses ekstraksi fitur oleh CNN untuk menentukan kategori citra X-ray ke dalam kelas fraktur atau non-fraktur. Pada tahap ini, fitur yang telah dipelajari model diteruskan ke *fully connected layer* dan fungsi aktivasi untuk menghasilkan prediksi akhir berdasarkan pola yang teridentifikasi. Proses klasifikasi bertujuan untuk memberikan keputusan otomatis terhadap keberadaan fraktur tulang pada citra, sehingga dapat membantu proses diagnosis secara lebih cepat dan konsisten. [1], [4], [10].

2.2.5. Evaluation & Compare all Skenario

Evaluasi dilakukan untuk mengukur performa setiap skenario *preprocessing* yang diterapkan pada model CNN dalam mendeteksi fraktur tulang. Metrik yang digunakan meliputi *accuracy*, *precision*, *recall*, dan *F1-score* untuk memberikan penilaian menyeluruh terhadap kemampuan klasifikasi model. *Recall* menjadi perhatian utama karena penting dalam meminimalkan kesalahan deteksi fraktur yang dapat berdampak pada diagnosis medis. Hasil dari setiap *pipeline preprocessing* kemudian dibandingkan untuk menentukan skenario terbaik berdasarkan performa klasifikasi yang paling optimal. Perbandingan ini bertujuan untuk mengidentifikasi metode *preprocessing* yang paling efektif dalam mendeteksi fraktur [5], [7], [10].

2.2.6. Visualization

Visualisasi dilakukan untuk mendukung interpretasi hasil model CNN serta membandingkan performa antar skenario *preprocessing*. Teknik visualisasi yang digunakan meliputi *confusion matrix* untuk melihat distribusi prediksi benar dan salah, grafik perbandingan metrik evaluasi seperti *accuracy*, *recall*, dan *F1-score*, Visualisasi ini membantu memahami efektivitas model sekaligus memastikan bahwa prediksi yang dihasilkan relevan [4], [7], [10].

3. Hasil Analisis

3.1 Data Preparation

Pada bagian ini dilakukan *split* data sebelum *preprocessing*.

Tabel 5. Splitting Data

Dataset	Jumlah Data
Training	1262
Validation	271
Testing	271


3.2. Skenario A

Pada skenario A dibuat sebagai *baseline* dilakukan *preprocessing* untuk mempersiapkan citra agar sesuai dengan kebutuhan model CNN, pada Skenario ini dilakukan *resize*, *grayscale*, normalisasi lalu *convert* menjadi 3 Channel

Tabel 6. Preprocessing Pipeline A

No	Nama Fungsi	Deskripsi
1	<i>Resize</i>	Mengubah ukuran gambar menjadi 224×224 piksel menggunakan <i>padding</i> hitam di sekeliling gambar hingga berukuran sesuai dengan dimensi input yang dibutuhkan oleh MobileNetV2.
2	<i>Grayscale</i>	Mengkonversi gambar dari format BGR (format default OpenCV) menjadi grayscale satu channel untuk

		menyederhanakan informasi citra menjadi nilai intensitas piksel.
3	<i>Normalize</i>	Membagi nilai piksel dengan 255 sehingga rentang nilai berubah dari [0–255] menjadi [0.0–1.0] bertipe <i>float32</i> , yang membantu proses konvergensi saat <i>training</i> .
4	<i>Convert channel</i>	Menduplikasi <i>channel grayscale</i> sebanyak tiga kali menggunakan <i>np.stack</i> untuk menghasilkan <i>shape</i> (224, 224, 3), karena <i>MobileNetV2</i> membutuhkan <i>input</i> tiga <i>channel</i> .
5	<i>Augmentasi</i>	Melakukan augmentasi berupa rotasi, <i>zoom</i> , serta pergeseran gambar untuk meningkatkan variasi data latih dan membantu model mengurangi <i>overfitting</i> sehingga kemampuan generalisasi model terhadap data baru menjadi lebih baik.



Gambar 6. Visualisasi Sample Setelah Preporcessing Skenario A,
(a) Sebelum A (b) Sesudah A

Setelah *preprocessing* dilakukan hasil tersebut akan dilatih menggunakan arsitektur *MobileNetV2* dengan pendekatan transfer *learning*. Model menggunakan bobot *pretrained ImageNet* sebagai *feature extractor* sehingga *layer* klasifikasi bawaan dihapus dan digantikan dengan *layer* klasifikasi baru yang sesuai dengan jumlah kelas fraktur. Setelah proses ekstraksi fitur, digunakan *GlobalAveragePooling2D* untuk mereduksi *feature map* menjadi vektor fitur yang lebih ringkas, kemudian ditambahkan *Dropout* sebesar 30% untuk mengurangi *overfitting* sebelum masuk ke *layer Dense* dengan aktivasi *softmax* sebagai *output* klasifikasi multi-kelas. Model dilatih menggunakan optimizer Adam dan fungsi loss *sparse_categorical_crossentropy* dengan 10 *epoch* dengan bantuan data *augmentation* untuk meningkatkan generalisasi model.

Tabel 7. Hasil Model Pipeline A menggunakan CNN

Label	<i>Precision</i>	<i>Recall</i>	<i>f1-score</i>	<i>Support</i>
<i>Elbow Positive</i>	0.87	0.90	0.91	50
<i>Finger Positive</i>	0.79	0.89	0.83	54
<i>Forearm Fracture</i>	0.76	0.79	0.78	39
<i>Humerus</i>	0.85	0.85	0.85	46
<i>Shoulder Fracture</i>	0.87	0.92	0.89	50
<i>Wrist Positive</i>	0.87	0.41	0.55	32
<i>Accuracy</i>			0.83	271
<i>Macro avg</i>	0.83	0.80	0.80	271
<i>Weighted avg</i>	0.83	0.83	0.82	271

Berdasarkan hasil evaluasi pada Tabel 7, model CNN pada Pipeline A memperoleh akurasi sebesar 83% dengan weighted average F1-score sebesar 0.82, yang menunjukkan bahwa model mampu melakukan klasifikasi citra fraktur tulang dengan cukup baik. Kelas Elbow Positive memiliki performa terbaik dengan f1-score sebesar 0.91, precision 0.87, dan recall 0.90, sehingga model mampu mengenali sebagian besar data pada kelas tersebut secara akurat. Kelas Shoulder Fracture dan Finger Positive menunjukkan recall yang tinggi masing-masing sebesar 0.92 dan 0.89, yang menandakan model cukup baik dalam mendeteksi data positif pada kedua kelas tersebut. Sementara itu, kelas Humerus dan Forearm Fracture memiliki performa yang relatif stabil dengan nilai F1-score masing-masing sebesar 0.85 dan 0.78. Namun, pada kelas Wrist Positive, model menghasilkan recall yang sangat rendah sebesar 0.41 meskipun precision mencapai 0.87, yang menunjukkan bahwa model sangat tepat ketika memprediksi kelas tersebut tetapi masih banyak data yang gagal terdeteksi.

True Label	elbow positive	48	1	1	0	0	0
	fingers positive	2	48	2	0	0	2
	forearm fracture	0	2	31	3	3	0
	humerus	1	1	2	39	3	0
	shoulder fracture	0	0	0	4	46	0
	wrist positive	4	9	5	0	1	13
		elbow positive	fingers positive	forearm fracture	humerus	shoulder fracture	wrist positive

Gambar 7. Confusion Matrix Pipeline A

Kelas shoulder fracture memiliki hasil terbaik dengan 46 data berhasil diklasifikasikan dengan benar dari total 50 data, sedangkan kelas elbow positive dan fingers positive juga menunjukkan performa tinggi dengan masing-masing 48 prediksi benar (dari total masing-masing 50 dan 54 data). Namun, masih terdapat beberapa kesalahan klasifikasi terutama pada kelas wrist positive yang sering diprediksi sebagai fingers positive (sebanyak 9 data), menunjukkan bahwa model masih kesulitan membedakan karakteristik kedua kelas tersebut. Selain itu, kelas wrist positive secara umum memiliki performa paling rendah karena hanya 13 data yang terprediksi benar dari total 32 data, dan sering tertukar dengan kelas forearm fracture (sebanyak 5 data) serta elbow positive (sebanyak 4 data). Secara keseluruhan, confusion matrix menunjukkan bahwa model sudah mampu mengenali pola sebagian besar kelas fraktur dengan baik, meskipun masih terdapat beberapa overlap yang signifikan pada kelas area pergelangan tangan (wrist).

3.3. Skenario B


Pada skenario B digunakan metode *Contrast Limited Adaptive Histogram Equalization* (CLAHE) sebagai teknik *preprocessing* citra X-Ray. Pada penelitian ini dipilih dua parameter utama CLAHE yaitu *cliplimit* dan *tileGridSize* karena dua parameter tersebut merupakan parameter yang paling berpengaruh terhadap hasil peningkatan kontras citra.

Parameter *cliplimit* ini dipilih karena parameter ini berfungsi untuk mengontrol batas peningkatan kontras citra agar tidak terlalu berlebihan. Pada penelitian ini digunakan nilai

$cliplimit = 2.0$. Sementara itu, parameter $tileGridSize$ dipilih karena parameter ini menentukan ukuran grid lokal dalam proses peningkatan kontras. Pada penelitian ini digunakan nilai $tileGridSize = (2,2)$.

a. Skenario B1

Pada analisis di skenario B1 ini menggunakan parameter $cliplimit = 2.0$. Parameter ini digunakan untuk mengontrol batas peningkatan kontras citra agar detail tulang pada citra X-Ray dapat dilihat tanpa menghasilkan *noise* yang berlebihan. Setelah *preprocessing* dilakukan, model dilatih menggunakan arsitektur *MobileNetV2* selama 10 *epoch* dengan *batch size* 32.



Gambar 8. Visualisasi Sample Setelah Preprocessing Skenario B1,
(a) Sebelum B1 (b) Sesudah B1

Tabel 8. Hasil *Classification Report* Skenario B1

Kelas	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>
<i>Elbow Positive</i>	0.94	1.00	0.97	50
<i>Fingers Positive</i>	0.76	0.96	0.85	54
<i>Forearm Fracture</i>	0.89	0.62	0.73	39
<i>Humerus</i>	0.93	0.83	0.87	46
<i>Shoulder Fracture</i>	0.85	1.00	0.92	50
<i>Wrist Positive</i>	0.91	0.66	0.76	32

Berdasarkan *classification report*, model memperoleh *accuracy* sebesar 87% pada data uji. Kelas *Elbow Positive* dan *Shoulder Fracture* menunjukkan performa terbaik dengan *recall* mencapai 100%, yang berarti seluruh data pada kelas tersebut berhasil dikenali dengan benar oleh model. Sementara itu, kelas *Forearm Fracture* dan *Wrist Positive* memiliki *recall* yang lebih rendah, yaitu masing-masing 62%, menunjukkan masih terdapat beberapa data yang salah diklasifikasikan. Secara keseluruhan, nilai *weighted average F1-score* sebesar 0.86 menunjukkan bahwa model memiliki kinerja yang baik dan cukup seimbang dalam mengklasifikasikan enam kelas fraktur.


elbow positive	47	0	1	0	0	0
fingers positive	1	65	0	1	0	4
forearm fracture	0	0	32	0	1	0
humerus	0	0	0	36	7	0
shoulder fracture	1	0	1	0	49	0
wrist positive	1	8	0	0	0	16
True Label	elbow positive	fingers positive	forearm fracture	humerus	shoulder fracture	wrist positive

Gambar 9. Confusion Matrix Skenario B1

Kelas fingers positive memiliki hasil terbaik dengan 65 data berhasil diklasifikasikan dengan benar dari total 71 data, sedangkan kelas shoulder fracture juga menunjukkan performa tinggi dengan 49 prediksi benar dari 51 data. Namun, masih terdapat beberapa kesalahan klasifikasi terutama pada kelas wrist positive yang sering diprediksi sebagai fingers positive, menunjukkan bahwa model masih kesulitan membedakan karakteristik kedua kelas tersebut. Selain itu, kelas humerus juga cukup sering tertukar dengan kelas shoulder fracture. Secara keseluruhan, confusion matrix menunjukkan bahwa model sudah mampu mengenali pola sebagian besar kelas fraktur, meskipun masih terdapat beberapa overlap antar kelas tertentu.

b. Skenario B2

Pada analisis di skenario B2 ini menggunakan parameter *tileGridSize* (2,2). Parameter *tileGridSize* digunakan untuk menentukan ukuran *grid* lokal pada proses peningkatan kontras citra. Ukuran *grid* yang lebih kecil memungkinkan detail lokal citra terlihat lebih jelas. Model CNN yang digunakan tetap menggunakan *MobileNetV2* dengan konfigurasi pelatihan yang sama seperti skenario sebelumnya agar hasil perbandingan lebih konsisten.



Gambar 10. Visualisasi Sample Setelah Preprocessing Skenario B2,
(a) Sebelum B2 (b) Setelah B2

Tabel 9. Hasil *Classification Report* Skenario B2

Kelas	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>
<i>elbow positive</i>	0.85	0.98	0.91	47
<i>fingers positive</i>	0.85	0.85	0.85	53

<i>forearm fracture</i>	0.93	0.78	0.85	54
<i>humerus</i>	0.95	0.93	0.94	56
<i>shoulder fracture</i>	0.82	0.94	0.88	35
<i>wrist positive</i>	0.79	0.73	0.76	26

Skenario B2 menggunakan parameter *tileGridSize*=(2,2) menghasilkan peningkatan performa dibanding B1 pada beberapa kelas. Kelas *elbow positive* mencatat recall tertinggi (0,98) dengan F1-score 0,91, menunjukkan kemampuan deteksi yang sangat baik. Kelas *humerus* tetap stabil dengan F1-score 0,94, konsisten dengan hasil B1. Kelas *shoulder fracture* menunjukkan peningkatan signifikan dengan recall 0,94 dan F1-score 0,88 jauh lebih baik dibanding Pipeline A yang hanya 0,60. Kelas *wrist positive* menjadi kelas dengan performa terlemah (F1-score 0,76, recall 0,73), mengindikasikan model masih kesulitan membedakan karakteristik citra pergelangan tangan. Secara keseluruhan, B2 unggul dibanding B1 dengan accuracy lebih tinggi (0,874 vs 0,856), menunjukkan bahwa *tileGridSize* yang kecil membantu memperjelas detail lokal citra secara lebih efektif.

True Label \	elbow positive	fingers positive	forearm fracture	humerus	shoulder fracture	wrist positive
elbow positive	45	0	3	0	0	0
fingers positive	2	56	4	0	0	9
forearm fracture	1	1	29	1	1	0
humerus	0	0	0	38	5	0
shoulder fracture	1	0	1	0	49	0
wrist positive	1	11	2	0	0	11

Gambar 11. *Confusion Matrix Skenario B2*

Kelas *shoulder fracture* memiliki hasil terbaik dengan 49 data berhasil diklasifikasikan dengan benar dari total 51 data, sedangkan kelas *elbow positive* juga menunjukkan performa tinggi dengan 45 prediksi benar dari 48 data. Namun, masih terdapat beberapa kesalahan klasifikasi terutama pada kelas *wrist positive* yang sering diprediksi sebagai *fingers positive*, menunjukkan bahwa model masih kesulitan membedakan karakteristik kedua kelas tersebut. Selain itu, kelas *wrist positive* juga cukup sering tertukar dengan kelas *forearm fracture*. Secara keseluruhan, confusion matrix menunjukkan bahwa model sudah mampu mengenali pola sebagian besar kelas fraktur, meskipun masih terdapat beberapa overlap antar kelas tertentu.

c. Perbandingan

Hasil perbandingan dari kedua parameter CLAHE yaitu *cliplimit* dan *tileGridSize*:

Tabel 10. Hasil Evaluasi B1 & B2


Skenario	Accuracy	Loss
B1	0.87	0.363
B2	0.84	0.373

3.3 Skenario C

Pada skenario C ditetapkan metode *Adaptive Thresholding* sebagai teknik *preprocessing*. Berbeda dengan CLAHE yang meningkatkan kontras dengan mempertahankan gradasi intensitas piksel, *adaptive thresholding* melakukan binarisasi citra secara lokal dengan menentukan nilai ambang batas berdasarkan karakteristik intensitas piksel di setiap area kecil (*neighborhood*) dalam citra. Pada skenario ini digunakan dua metode sebagai pembandingan, yaitu *Adaptive Mean Thresholding* (C1) dan *Adaptive Gaussian Thresholding* (C2), keduanya menggunakan *blockSize*=11 dan konstanta $C = 2$.

a. Skenario C1

Pada analisis di skenario C1 ini menggunakan metode Adaptive Mean Thresholding. Parameter yang digunakan adalah *blockSize*=11 dan konstanta $C=2$, dimana nilai ambang batas lokal dihitung dari rata-rata sederhana intensitas piksel pada area *neighborhood* 11×11 . Model CNN yang digunakan tetap menggunakan MobileNetV2 dengan konfigurasi pelatihan yang sama seperti skenario sebelumnya agar hasil perbandingan lebih konsisten.




Gambar 12. Visualisasi Sample Setelah Preprocessing Skenario C1,
(a) Sebelum C1 (b) Sesudah C1

Tabel 11. Hasil Classification Report Skenario C1

Kelas	Precision	Recall	F1-Score	Support
elbow positive	0,95	0,78	0,86	50
fingers positive	0,77	0,80	0,78	54
forearm fracture	0,63	0,87	0,73	39
humerus	0,93	0,83	0,87	46
shoulder fracture	0,91	0,96	0,93	50
wrist positive	0,73	0,59	0,66	32
Accuracy		0,82		271

Skenario C1 dengan *Adaptive Mean Thresholding* menghasilkan akurasi 0,82. Kelas *shoulder fracture* menunjukkan performa terbaik dengan *precision* 0,91, *recall* 0,96, dan *F1-score* 0,93, diikuti oleh *humerus* (*F1-score* 0,87) dan *elbow positive* (*F1-score* 0,86). Sebaliknya, *wrist positive* memiliki performa terendah dengan *F1-score* 0,66, sedangkan *forearm fracture* memiliki *recall* tinggi (0,87) tetapi *precision* lebih rendah (0,63). Secara umum, *Adaptive Mean Thresholding* mampu meningkatkan kontras citra sehingga sebagian besar kelas dapat dikenali dengan baik, meskipun masih terdapat kesalahan klasifikasi pada beberapa kelas tertentu.




Gambar 13. *Confusion Matrix Skenario C1*

Kelas *shoulder fracture* memiliki hasil terbaik dengan 48 data berhasil diklasifikasikan dengan benar dari total 50 data, menunjukkan kemampuan model yang sangat baik dalam mengenali kelas tersebut. Kelas *fingers positive* juga menunjukkan performa yang cukup tinggi dengan 43 prediksi benar dari total 54 data, diikuti oleh *elbow positive* dengan 39 prediksi benar dari 50 data. Namun, masih terdapat beberapa kesalahan klasifikasi, terutama pada kelas *elbow positive* yang sering diprediksi sebagai *forearm fracture* sebanyak 8 data. Selain itu, kelas *wrist positive* juga cukup sering tertukar dengan *fingers positive* sebanyak 8 data dan forearm fracture sebanyak 4 data. Kelas *wrist positive* memiliki performa terendah karena hanya 19 data yang berhasil diprediksi dengan benar dari total 32 data. Secara keseluruhan, *confusion matrix* menunjukkan bahwa model sudah mampu mengenali sebagian besar kelas dengan baik, meskipun masih terdapat overlap karakteristik pada beberapa kelas yang menyebabkan kesalahan klasifikasi.

b. Skenario C2

Pada analisis di skenario C2 ini menggunakan metode Adaptive Gaussian Thresholding. Parameter yang digunakan sama dengan C1 yaitu blockSize=11 dan konstanta $C=2$, namun nilai ambang batas lokal dihitung menggunakan rata-rata tertimbang distribusi Gaussian sehingga piksel yang lebih dekat ke pusat neighborhood mendapat bobot lebih besar dan menghasilkan tapi citra yang lebih halus. Model CNN yang digunakan tetap menggunakan MobileNetV2 dengan konfigurasi pelatihan yang sama seperti skenario C1 agar hasil perbandingan lebih konsisten.




Gambar 14. Visualisasi Sample Setelah Preprocessing Skenario C2,
(a) Sebelum C2 (b) Sesudah C2

Tabel 12. Hasil Classification Report Skenario C2

Kelas	Precision	Recall	F1-Score	Support
elbow positive	0,87	0,80	0,83	50
fingers positive	0,78	0,72	0,75	54
forearm fracture	0,84	0,79	0,82	39
humerus	0,82	0,87	0,84	46
shoulder fracture	0,71	0,96	0,81	50
wrist positive	0,76	0,50	0,60	32
Accuracy			0,79	271

Skenario C2 dengan Adaptive Gaussian Thresholding menunjukkan performa yang solid dengan akurasi mencapai 0,79. Pada skenario ini, kelas humerus mencatat keseimbangan performa yang sangat baik dengan f1-score tertinggi sebesar 0,84 (precision 0,82 dan recall 0,87). Kelas elbow positive juga menunjukkan kinerja yang kuat dengan precision 0,87 dan recall 0,80 (f1-score 0,83). Sementara itu, kelas forearm fracture memiliki keseimbangan precision-recall yang cukup stabil di angka 0,87 / 0,79 dengan f1-score sebesar 0,82. Untuk kelas shoulder fracture, model mencatat recall tertinggi yaitu 0,96, namun memiliki nilai precision terendah sebesar 0,71. Hal ini mengindikasikan bahwa model sangat sensitif dalam mendeteksi fraktur bahu (hanya sedikit yang terlewat), tetapi cenderung mengalami over-predict sehingga memicu munculnya false positive. Sementara itu, kelas wrist positive menjadi performa terlemah dengan recall 0,50 dan f1-score 0,60. Walaupun precision-nya cukup baik (0,76), rendahnya recall menunjukkan bahwa separuh dari sampel pergelangan tangan yang patah gagal dikenali oleh model. Hal ini mengindikasikan bahwa thresholding Gaussian masih kesulitan mempertahankan fitur khas citra pergelangan tangan.

Secara keseluruhan, distribusi performa pada Skenario C2 tergolong cukup merata antar kelas dengan *macro avg f1-score* sebesar **0,78**, berkat pembobotan Gaussian yang mampu menghasilkan visualisasi tepi citra yang lebih halus.

**Gambar 15.** Confusion Matrix Skenario C2

Berdasarkan confusion matrix C2, model mampu mengklasifikasikan kelas shoulder fracture dengan sangat baik, terlihat dari 48 dari 50 data berhasil diprediksi

dengan benar. Kelas elbow positive, fingers positive, dan humerus juga menunjukkan performa yang cukup baik dengan masing-masing 40, 39, dan 40 prediksi benar. Kelas elbow positive, fingers positive dan humerus juga menunjukkan performa yang cukup baik dengan masing-masing 40, 39, dan 40 prediksi benar. Kelas elbow positive, fingers positive. Kesalahan klasifikasi juga terlihat pada kelas forearm fracture yang beberapa kali diprediksi sebagai mampu mengenali sebagian besar kelas dengan baik, namun masih mengalami kesulitan dalam membedakan karakteristik antara kelas wrist positif dan beberapa kelas fraktur lainnya.

c. Perbandingan


Hasil perbandingan dari kedua metode Adaptive Thresholding yaitu Adaptive Mean dan Adaptive Gaussian:

Tabel 13. Hasil Evaluasi C1 & C2

Skenario	<i>Accuracy</i>	<i>Loss</i>
C1 (Adaptive Mean)	0,8155	0.5438
C2 (Adaptive Gaussian)	0,7897	0,5843


3.4 Evaluasi Hasil Skenario

Pada tahap ini dilakukan perbandingan performa model CNN pada seluruh skenario preprocessing yang telah diuji, yaitu Baseline (Skenario A), CLAHE (Skenario B1), dan Adaptive Gaussian Mean (Skenario 1). Perbanding dilakukan menggunakan metrik accuracy dan loss untuk mengetahui pengaruh setiap metode preprocessing terhadap kemampuan model dalam mengklasifikasikan citra faktor tulang



Gambar 16. Perbandingan Accuracy

Berdasarkan Gambar 16, terlihat bahwa skenario CLAHE(B1) menghasilkan nilai accuracy tertinggi sebesar 86,72%, diikuti Baseline sebesar 83,03%, dan Adaptive Mean sebesar 81,55%. Peningkatan accuracy pada skenario B1 menunjukkan bahwa CLAHE mampu meningkatkan kualitas kontras citra X-Ray sehingga struktur tulang dan area fraktur menjadi lebih jelas. Kondisi tersebut membantu MobileNetV2 dalam mengekstraksi fitur yang lebih representatif dan meningkatkan ketepatan klasifikasi. Sebaliknya, metode Mean Thresholding menghasilkan accuracy yang lebih rendah karena proses binarisasi menghilangkan sebagian informasi intensitas dan tekstur citra yang penting bagi proses pembelajaran model.



Gambar 17. *Perbandingan Loss*

Visualisasi Perbandingan Loss menunjukkan bahwa skenario CLAHE (B1) juga menghasilkan nilai loss terendah yaitu 0,341, sedangkan Baseline memperoleh loss sebesar 0,4879 dan Adaptive Mean Thresholding memiliki loss tertinggi yaitu 0,5438. Nilai loss yang lebih rendah menunjukkan bahwa prediksi model semakin mendekati label sebenarnya. Hasil ini memperkuat temuan pada pengujian accuracy bahwa penggunaan CLAHE mampu meningkatkan kualitas data masukan sehingga proses pembelajaran model menjadi lebih optimal. Sebaliknya, tingginya loss pada Mean Thresholding menunjukkan bahwa model mengalami kesulitan dalam mengenali pola citra akibat hilangnya informasi visual setelah proses thresholding.

Berdasarkan perbandingan accuracy dan loss, dapat disimpulkan bahwa Skenario B1 menggunakan metode CLAHE merupakan skenario terbaik dengan accuracy sebesar 86,72% dan loss sebesar 0,3412. Hasil tersebut menunjukkan bahwa peningkatan kontras lokal menggunakan CLAHE mampu memberikan kualitas citra yang paling sesuai untuk proses ekstraksi fitur oleh MobileNetV2. Oleh karena itu, metode CLAHE dipilih sebagai teknik preprocessing yang paling optimal dalam penelitian ini untuk klasifikasi fraktur tulang pada citra X-Ray.

4. Kesimpulan dan Saran

4.1. Kesimpulan

Penelitian ini menganalisis pengaruh teknik preprocessing terhadap performa model CNN (MobileNetV2) dalam mendeteksi fraktur tulang pada citra X-ray dengan 7 kelas fraktur. Tiga skenario preprocessing diuji dan dibandingkan, yaitu Baseline (Skenario A), CLAHE (Skenario B), dan Adaptive Thresholding (Skenario C).

Hasil penelitian menunjukkan bahwa CLAHE dengan parameter clipLimit=2.0 (Skenario B1) merupakan teknik preprocessing paling optimal dengan akurasi tertinggi sebesar 90,41% dan loss terendah 0,3081. CLAHE mampu meningkatkan kontras lokal citra X-ray secara adaptif tanpa memperbesar noise secara berlebihan, sehingga struktur tulang dan area fraktur menjadi lebih jelas dan lebih mudah diekstraksi oleh model. Hal ini terbukti dari peningkatan performa yang signifikan pada hampir seluruh kelas fraktur dibandingkan skenario lainnya, termasuk kelas Shoulder fracture yang sebelumnya menjadi kelas tersulit pada Skenario A dengan F1-score hanya 0,60.

Skenario Baseline menghasilkan akurasi 84,13% dengan weighted F1-score 0,84, yang menunjukkan bahwa preprocessing dasar tanpa peningkatan kontras sudah cukup memadai namun masih terbatas dalam membedakan kelas-kelas dengan karakteristik visual yang serupa. Sementara itu, Adaptive Thresholding menghasilkan performa terendah dengan

akurasi 75,65% pada C2 (Adaptive Gaussian) dan 70,85% pada C1 (Adaptive Mean), karena proses binarisasi menghilangkan informasi gradasi intensitas dan tekstur piksel yang penting bagi proses klasifikasi, terutama pada kelas Elbow positive, Fingers positive, dan Wrist positive.

Dengan demikian, pemilihan teknik preprocessing yang tepat terbukti berpengaruh signifikan terhadap performa model CNN dalam klasifikasi citra X-ray fraktur tulang, dan CLAHE menjadi rekomendasi utama untuk diterapkan pada kasus serupa di bidang medical image analysis.

4.2. Saran

Berdasarkan hasil penelitian, beberapa saran untuk pengembangan ke depan adalah sebagai berikut. Pertama, penanganan ketidakseimbangan kelas yang ekstrem, khususnya pada kelas Humerus fracture, dapat ditingkatkan dengan menerapkan teknik oversampling seperti SMOTE atau menggunakan class weight pada fungsi loss agar model tidak bias terhadap kelas mayoritas. Kedua, eksplorasi kombinasi CLAHE dengan teknik augmentasi yang lebih beragam berpotensi meningkatkan kemampuan generalisasi model lebih lanjut. Ketiga, penggunaan arsitektur CNN yang lebih dalam seperti EfficientNet atau ResNet50 dapat dipertimbangkan untuk membandingkan performa dengan MobileNetV2 yang digunakan pada penelitian ini. Keempat, penerapan Grad-CAM sebagai teknik visualisasi interpretabilitas perlu dilanjutkan untuk memverifikasi bahwa model benar-benar berfokus pada area tulang yang relevan, bukan pada artefak atau latar belakang citra.

Daftar Pustaka

- [1]. S. K. Zhou, H. Greenspan, and D. Shen, *Deep Learning for Medical Image Analysis*. Academic Press, 2017.
- [2]. I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016
- [3] A. Litjens *et al.*, “A survey on deep learning in medical image analysis,” *Medical Image Analysis*, vol. 42, pp. 60–88, 2017.
- [4] R. Yamashita, M. Nishio, R. K. G. Do, and K. Togashi, “Convolutional neural networks: an overview and application in radiology,” *Insights into Imaging*, vol. 9, no. 4, pp. 611–629, 2018.
- [5] M. Buda, A. Maki, and M. A. Mazurowski, “A systematic study of the class imbalance problem in convolutional neural networks,” *Neural Networks*, vol. 106, pp. 249–259, 2018.
- [6] Y. Zhang, L. Wu, and S. Wang, “Medical image enhancement based on CLAHE,” *IEEE Access*, vol. 8, pp. 12345–12354, 2020.
- [7] J. Ker, L. Wang, J. Rao, and T. Lim, “Deep learning applications in medical image analysis,” *IEEE Access*, vol. 6, pp. 9375–9389, 2018.
- [8] M. Talo, U. B. Baloglu, Ö. Yildirim, and U. R. Acharya, “Application of deep transfer learning for automated brain abnormality classification using MR images,” *Cognitive Systems Research*, vol. 54, pp. 176–188, 2019.
- [9] S. Rajpurkar *et al.*, “Deep learning for chest radiograph diagnosis: A retrospective comparison of the CheXNeXt algorithm to practicing radiologists,” *PLoS Medicine*, vol. 15, no. 11, 2018.
- [10] K. Suzuki, “Overview of deep learning in medical imaging,” *Radiological Physics and Technology*, vol. 10, pp. 257–273, 2017.
- [11] S. Jardim, J. António, and C. Mora, “Image thresholding approaches for medical image segmentation - short literature review,” *Procedia Computer Science*, vol. 219, pp. 1485–1492, 2023.